

聚类感知与细粒度反馈驱动的大模型智能体系统优化方法

欧阳钡¹, 张捷², 白昱阳¹, 徐焰², 张俊¹⁺, 苏运², 高天露¹, 戴宇欣¹

1. 武汉大学 电气与自动化学院, 湖北 武汉 430072

2. 国家电网 上海市电力公司, 上海 200540

+ 通信作者 E-mail: Jun.zhang.ee@whu.edu.cn

摘要: 针对现有大模型多智能体系统优化方法在自动化程度、搜索效率和优化质量等方面难以满足实际应用需求的问题, 提出一种聚类感知与细粒度反馈驱动的多智能体系统自动优化方法 (CAFG)。首先, 定义多智能体系统设计意图相似度度量方法, 通过分析拓扑结构、节点调用和设计意图等多维度特征, 在搜索过程中动态识别并合并相似多智能体系统分支, 有效规避重复探索。其次, 构建节点级反馈机制, 记录节点输入输出特征并引入评分机制, 实现细粒度提示词优化。实验结果表明, 本方法在六个基准数据集上均取得了 SOTA 水平, 平均得分 84.2, 为多智能体系统自动化优化提供了新思路。

关键词: 大模型; 多智能体系统; 社区发现算法; 细粒度提示优化; 自动化优化

文献标志码: A **中图分类号:** TP389.1

Cluster-Awareness and Fine-Grained Feedback Driven Optimization Method for LLM-based Multi-Agent Systems

Ouyang Chao¹, Zhang Jie², Bai Yu-Yang¹, Xu Yan², Zhang Jun¹⁺, Su Yun², Gao Tian-Lu¹, Dai Yu-Xin¹

1. School of Electrical Engineering and Automation, Wuhan University, Wuhan, 430072, China

2. Shanghai Municipal Electric Power Company, State Grid, Shanghai, 200540, China

Abstract: Existing optimization methods for Large Language Model (LLM) based multi-agent systems face challenges in automation, search efficiency, and optimization quality. To address these issues, an automated optimization approach driven by cluster-awareness and fine-grained feedback (CAFG) is proposed. First, a similarity metric for multi-agent system design intent is defined. By analyzing multi-dimensional features such as topological structure, node invocation, and design intent, similar system branches are dynamically identified and merged during the search process to avoid redundant exploration. Second, a node-level feedback mechanism is

基金项目: 国家电网科技项目面向数字化电网韧性提升的人机协同智能决策技术研究及应用 (5700-202417336A-2-1-ZX)。

作者简介: 欧阳钡 (2003-), 男, 硕士研究生, 主要研究方向为计算机视觉和多智能体系统。张捷 (1974-), 大学本科, 高级工程师, 主要研究领域为电力系统与自动控制和能源技术。白昱阳 (1997-), 博士研究生, 主要研究领域为人工智能和电力系统。张俊 (1981-), 教授, 主要研究领域为人工智能和电力系统。徐焰 (1980-), 男, 工程硕士, 高级工程师, 主要研究领域为电力系统与智能电网和电网规划与运行。苏运 (1987-), 男, 研究生, 副高级工程师, 主要研究领域为电力系统自动化。高天露 (1994-), 博士研究生, 主要研究领域为人工智能和电力系统。戴宇欣 (1996-), 博士研究生, 博士后, 主要研究领域为人工智能和电力系统。

收稿日期: 2025-00-00 **修回日期:** 2025-00-00

constructed to record input and output features of nodes and introduce a scoring system for fine-grained prompt optimization. The proposed method achieves state-of-the-art (SOTA) performance on six benchmark datasets, with an average score of 84.2, providing a new direction for the automated optimization of multi-agent systems.

Key words: Large Language Model; Multi-agent System; Community Detection; Fine-grained Prompt Optimization; Automated Optimization

随着大语言模型 (Large Language Models, LLM) 技术的飞速发展, 基于 Transformer 架构的预训练模型已在诸多自然语言处理任务中展现出卓越的能力。然而, 面对需要多步推理、动态环境交互与多角色协同的复杂任务时, 单一 LLM 往往受限于其固有架构与知识静态性, 在泛化性、协作效率与持续适应方面存在明显不足。为突破这一局限, 研究者开始将目光投向多智能体系统 (Multi-Agent System, MAS) [1-6], 通过构建多个 LLM 智能体之间的协同机制, 以分布式架构实现更强大的整体智能。

多智能体系统通过模拟人类社会的协作机制, 将复杂任务分解为由多个智能体分别承担的子系统, 借助分布式架构实现任务的高效并行处理与决策融合, 显著提升了整体系统的表达能力与鲁棒性。该类系统通常由多个大语言模型智能体构成, 各智能体可扮演不同角色 (如决策者、执行者、评估者等) [2], 通过消息传递、资源共享与协商机制实现协同推理。得益于其良好的可扩展性与架构灵活性, 多智能体系统已在软件开发[3]、科学发现[4]、复杂游戏[5]、机器人协同控制[1]等多个领域展现出超越单一模型的性能。然而, 该类系统的性能高度依赖于智能体之间的协作拓扑结构设计以及每个智能体内部提示 (Prompt) 的精确优化。拓扑结构决定了信息流动与智能体间的交互模式, 而提示词则直接调控各个智能体的行为逻辑与输出质量。当前, 这些设计大多依赖专家经验与人工试错, 导致搜索空间随智能体数量与任务复杂度的增加呈指数级增长, 不仅效率低下, 也难以保证系统在动态环境中的泛化性与稳定性。因此, 如何实现多智能体系统自动化、高效与精准的优化, 已成为推动其从理论走向大规模实际应用的核心瓶颈。

研究界陆续提出了多种自动化方法以优化多智能体系统的构建过程。这些方法的核心思路在于将系统设计任务建模为一个结构化搜索问题, 通过算法自动探索智能体拓扑、提示策略与协作机制的最佳组合。例如, 文献[7]创新性地采用代码形式表征多智能体系统, 以支持复杂的控制逻辑, 并引入蒙特卡洛树搜索 (Monte Carlo Tree Search, MCTS[8]) 在庞大的设计空间中探索潜在的高性能结构。文献[4]则将多智能体系统建模为图结构, 并利用强化学习来优化节点间的连接关系, 实现了对智能体协作拓扑的自动调整。此外, 文献[9]对多智能体系统的拓扑单元进行了量化分析, 同时手动定义模块化组合, 而文献[10]则尝试通过改

进偏好对齐方法[11]提升大语言模型自身生成高质量多智能体系统的能力。尽管上述方法在不同层面上推动了多智能体系统优化的自动化进程, 但它们在搜索策略上普遍忽略了对已探索多智能体系统方案之间内在相似性的度量与利用。这种机制的缺失导致搜索过程呈现出较高的“盲目性”, 无法规避对功能与行为上高度同质化的多智能体系统分支的冗余探索。与此同时, 这些方法在优化过程中大多依赖于稀疏且粗粒度的终端反馈信号 (例如最终任务的成功与否), 这种单一信号难以解决经典的“信用分配”难题, 即无法精确评估每个智能体组件对最终结果的贡献, 这为具体的迭代优化 (如提示词调整) 带来了极大困难, 导致优化效率低下。

针对上述两大挑战, 本文做出了针对性的设计。其一, 为解决搜索冗余问题, 不同于[7]中 MCTS 或[4]中强化学习的“盲目”探索策略, 本文提出在优化流程中引入多智能体系统相似度感知的聚类机制。本文首先构建了一种多维度的相似度度量方法, 该方法突破了单一结构对比的局限, 综合考量了多智能体系统的拓扑结构 (Topology)、节点 (Node) 序列、历史演化模式以及节点语义特征。此度量方法能够量化不同多智能体系统方案在功能和行为层面的相似程度。在此基础上, 本文采用 Louvain 社区发现算法[12], 对搜索空间中的多智能体系统进行动态聚类, 将相似的多智能体系统划分到同一家族中。这种设计的核心优势在于, 它使优化器能够从宏观上识别功能同质化的区域, 从而有效规避重复探索。

其二, 为解决信用分配难题, 区别于现有方法[7-10]对稀疏、粗粒度终端反馈的依赖, 提出一种节点级的细粒度反馈机制。本文将多智能体系统中的各智能体称为节点, 而多智能体系统的最终性能就是其内部所有节点共同作用的结果。区别于以往依赖单一最终得分的优化方式, 该机制在多智能体系统执行时, 为各节点增加输入质量的量化评估环节。此举的益处在于将全局的、端到端的优化目标, 分解为局部的、精确的节点级优化信号, 为实现各节点提示词的精准调整提供了可靠依据。

综上所述, 本文提出一种聚类感知与细粒度反馈驱动 (Cluster-Aware Search and Fine-Grained Feedback, CAFG) 的多智能体系统自动优化方法。该方法通过引入多维度相似度度量与社区发现机制, 显著提升了在复杂搜索空间中的搜索效率; 同时, 通过节点级的细粒度反馈, 实现了对提示词的精准、高效优化。

本文的主要贡献可概括如下:

(1) 提出了一种多维度的多智能体系统相似度量方法。该方法综合了多智能体系统的拓扑特征、历史演化模式、节点序列以及提示词语义信息,构建了一个全面的相似性评估模型,能够准确量化不同多智能体系统方案在功能与行为上的关联性。

(2) 设计了基于社区发现算法的相似度感知聚合机制。将多智能体系统相似度分析与 Louvain 社区发现算法相结合,实现了对搜索空间中功能相近多智能体系统的动态聚类。通过在聚类家族内进行代表性选择与经验共享,该机制能够有效剪枝冗余的搜索路径,显著提升优化算法的收敛速度与全局探索能力。

(3) 构建了节点级的细粒度反馈与提示优化闭环。创新地引入了节点级的输入质量评分机制,将多智能体系统的端到端性能评估分解为各节点的具体贡献。这种细粒度的反馈信号为提示词的自动化迭代提供了精确的指导,提升了优化过程的指向性与效率。

1 相关工作

近年来,随着大语言模型能力的飞速发展,多智能体系统(MAS)的自动优化已成为研究热点。该类研究致力于应对多智能体协作中组合复杂度高、人工设计成本大等关键挑战。现有方法通常将该问题建模为一个结构化搜索问题,通过自动化算法探索智能体拓扑、提示工程与协作机制的最佳组合。目前的主流技术路线大致可分为以下几类:

1.1 基于元智能体的生成式方法

一个新兴范式是利用上层的“元智能体”来自动生成,以及动态编排整个多智能体系统。在此方向上,部分工作着眼于程序化生成与合成。例如,文献[13]提出一种自动化设计框架,将系统定义为图灵完备的代码,利用元智能体在一个“设计-自我反思-评估”的迭代循环中以代码形式编写并优化全新架构。为提升元智能体生成逻辑的鲁棒性,文献[14]在多智能体风险决策研究中指出了环境非平稳性等风险,为元智能体嵌入风险感知机制提供了依据;文献[15]关于多智能体博弈、学习与控制的交叉研究,则为其平衡合作与竞争关系提供了理论支撑。另一类工作则聚焦于任务执行时的动态团队编排。如文献[16]引入了一个“规划者”与“观察者”智能体为任务动态生成定制化团队;文献[17]则将此思想推向了更高的动态性,提出了“自适应对话中团队构建”范式,其“队长”智能体在任务的每个步骤中都会动态组建和管理专门的子团队。这类生成式方法极大地提升了系统的灵活性,但其性能高度依赖于元智能体自身的推理与生成能力,且在搜索过程中往往缺乏系统性的结构化探索策略。

1.2 基于离散空间搜索的优化方法

与生成式方法不同,另一条主流技术路线是直接

在离散的配置空间中进行搜索,其中演化算法(Evolutionary Algorithm, EA)和蒙特卡洛树搜索(MCTS)是代表性技术。在演化算法方面,文献[4]将多智能体系统建模为计算图,并利用EA对图的连接拓扑进行优化。为解决传统EA易产生无效或脆弱系统架构的问题,文献[18]创新地使用Mermaid语法作为多智能体系统的可验证中间表示,确保了所有生成的系统架构在执行前都是静态可验证的。在MCTS方面,文献[7]是该方向的代表,它将多智能体系统表示为代码形式,并引入MCTS算法,利用树结构经验与执行反馈来探索和优化系统结构。尽管这些方法在结构化搜索上取得了进展,但它们在搜索策略上普遍缺乏对候选方案之间内在相似性的有效利用。无论是MCTS的随机探索还是EA的迭代变异,当演化出的不同系统在功能逻辑上趋于一致时,现有框架难以识别这种语义层面的相似性,从而导致冗余评估,显著降低了优化效率。

1.3 其他优化范式

此外,还有研究者尝试将离散的系统结构选择问题映射到连续空间中进行优化,以提升搜索效率。例如,文献[10]将多智能体系统优化重构为连续空间中的梯度优化问题。文献[11]错误!未找到引用源。提出的数字孪生架构下基于GAN(Generative Adversarial Network)增强的多智能体深度强化学习方法,也为离散结构向连续空间转化提供了新路径。在此连续优化范式中,一个关键子方向聚焦于作为协作核心的通信拓扑优化。其中,文献[20]创新地使用变分图自编码器(Variable Graph Auto Encoder, VGAE^[21])将拓扑设计问题转化为连续潜在空间中的优化。与之不同,文献[22]则探索了更为动态的拓扑适应机制,它在任务运行时通过计算“智能体重要性得分”来动态修剪通信网络。这些方法还可与Li等人[23]梳理的通信机制(如基于注意力的通信学习、鲁棒通信屏蔽)相结合,以提升适配性与效率。在高级学习策略方面,受模型无关元学习(Model Agnostic Meta Learning, MAML^[24])启发的文献[25],旨在学习一个具有良好泛化性的“元模型”,以快速适应不同任务。这些方法为拓扑优化提供了新思路,但目前的研究大多集中于结构层面,对智能体内部行为(如提示)的优化涉及较少。

2 问题定义

本章旨在为后续方法论的阐述建立形式化基础。本文将首先定义多智能体系统的核心构成要素,然后将其自动化优化过程构建为一个数学优化问题,并最终点明该问题所面临的核心挑战,从而引出本文所提出的解决方案。

2.1 多智能体系统的形式化定义

一个多智能体系统 W 是一个用于完成特定任务 T 的有向图,旨在实现智能体间的协作与信息流转。本文将多智能体系统 W 定义为一个二元组:

$$W = (A, G) \quad (1)$$

其中: $A = \{a_1, a_2, \dots, a_n\}$ 代表多智能体系统 $V = A$ 中包




图1 多智能系统优化的搜索空间和搜索结果

Fig.1 English Search space and search results optimized by multi-intelligent systems

含的智能体集合。每个智能体 a_i 负责执行一项子任务，其行为由一个特定的提示词 (Prompt) p_i 所决定。因此，一个智能体的优化变量主要是其提示词 $p_i \in \mathcal{P}$ ，其中 $\mathcal{P}$ 是有可能提示的巨大空间。智能体的选择，即决定集合 A 本身，也是优化的一个方面。 $G = (V, E)$ 代表智能体的协作拓扑结构，是一个有向图。其中，节点集合 V 与智能体集合 A 一一对应。边集合 $E = \{e_{ij}\}$ 代表了智能体之间的连接关系与信息流向，即智能体 a_i 的输出将作为智能体 a_j 的输入。连接方式（如信息是直接传递、汇总还是筛选后传递）是优化拓扑结构 G 的关键。

因此，一个多智能体系统 W 的搜索空间 Ω 是由智能体选择、提示设计以及拓扑结构共同决定的。

2.2 多智能体系统的自动优化目标

如图1所示，在给定一个上层任务 T 的前提下，多智能体系统的自动优化目标是，从庞大的设计空间 Ω 中，搜索到一个最优的多智能体系统配置 W^* ，使其在执行任务 T 时的表现最优。本文可以将此目标形式化地表达为一个最小化问题：

$$W^* = \arg \min_{W \in \Omega} C(W, T) \quad (2)$$

其中， $C(W, T)$ 是一个评估函数，用于量化多智能体系统 W 在处理任务 T 时的误差，公式 (2) 中得分越低表示表现越好。根据任务 T 的性质，本文采用基于 LLM 的评估，即利用一个能力强大的 LLM 作为裁

判，对生成结果进行打分和评估，以模拟人类偏好。

为了高效求解上述优化问题，特别是解决搜索空间巨大且存在大量功能冗余的挑战，本文在第3章提出了一种基于相似度图的聚类感知搜索机制。

3 基于相似度图的多智能体系统聚类感知、选择与优化

为解决引言中提出的搜索冗余问题，本章提出一种全新的搜索机制。其核心思想是将离散、孤立的多智能体系统方案，转化为一个相互连接的“相似度图”，并利用社区发现算法识别出图中的家族，最终通过家族间探索和家族内剪枝，实现对搜索空间的高效遍历。为实现这一目标，核心挑战在于如何科学地度量两个多智能体系统 (MAS) 之间的相似性。

然而，MAS 是一种复杂的混合结构，单一维度的度量（如仅比较拓扑结构或代码）是片面且不足的。例如，两个 MAS 可能拓扑结构相似，但因节点内部的提示词 (Prompt) 逻辑不同而功能迥异；反之，两个 MAS 也可能代码实现不同，但其宏观的拓扑和调用序列却高度一致，导致功能同质化。

因此，如图2所示，本文提出一种专为 MAS 自动优化场景设计的多维度相似度度量方法。该方法突破了单一对比的局限，通过综合考量 MAS 的拓扑特征 ($S_{types}, S_{stages}, S_{parallel}$)、执行流程 (S_{seq}) 以及代码实现 (S_{struct})，构建了一个全面的相似性评估模型。然后，基于该评估模型应用 Louvain 社区发现算法，对生成的多智能体系统相似度图进行划分。

3.1 多智能体系统的多维相似度度量

给定两个待比较的多智能体系统 W_a 和 W_b ，本文的目标是计算一个综合相似度得分 $S_{total}(W_a, W_b) \in [0, 1]$ 。该得分由以下几部分组成：

3.1.1 多智能体系统结构相似度

该维度旨在衡量多智能体系统在代码实现层面的相似性，关注其编程范式与控制流。为排除干扰，首先对多智能体系统的源代码 C 进行预处理，移除其中的注释、字符串字面量等非结构性信息，得到纯化的逻辑代码 C' 。随后，本文通过一个自定义的词法分析器 (Tokenizer) 将 C' 转化为一个结构化特征词袋 $F(W)$ ，其中包含了节点的使用频率、提示词调用顺序以及关键控制流等信息。基于此特征表示，本文利用词频-逆文档频率 (TF-IDF) 算法将每个多智能体系统的特征词袋转换为高维向量 $v_{struct} = TF-IDF(F(W))$ 。两个多智能体系统的结构相似度则通过余弦相似度来计算：

$$S_{struct}(W_a, W_b) = \frac{v_{struct,a} \cdot v_{struct,b}}{\|v_{struct,a}\| \cdot \|v_{struct,b}\|} \quad (3)$$




图2 聚类感知与细粒度反馈驱动的自动优化方法

Fig.2 Cluster-aware and fine-grained feedback-driven automatic optimization method

3.1.2 拓扑相似度

该维度聚焦于多智能体系统作为计算图的宏观拓扑特征，独立于具体的代码实现细节，由节点类型相似度 S_{types} 、阶段数相似度 S_{stages} 、并行度相似度 $S_{parallel}$ 和调用序列相似度 S_{seq} 组成：

S_{types} ：通过计算两个多智能体系统节点类型分布的“直方图交集”得到，并由节点总数较少的多智能体系统进行归一化，以反映其构成上的重叠程度。

$$S_{types}(W_a, W_b) = \frac{\sum_{t \in T_a \cap T_b} \min(D_a(t), D_b(t))}{\min(\sum_{t' \in T_a} D_a(t'), \sum_{t' \in T_b} D_b(t'))} \quad (4)$$

其中 $D_a(t)$ 、 $D_b(t)$ 表示类型为 t 的节点在 W_a 、 W_b 中出现的次数， T_a 、 T_b 是 W_a 、 W_b 中所有节点类型的集合。

S_{stages} ：基于两者阶段数的绝对差值进行线性惩罚。阶段数越接近，相似度越高。

$$S_{stages}(W_a, W_b) = \max(0, 1 - \beta_{stage} \cdot |N_{stages}(W_a) - N_{stages}(W_b)|) \quad (5)$$

其中惩罚因子 β_{stage} 设为 0.2， $N_{stages}(W)$ 为多智能体系统中主要的顺序执行步骤数量。

$S_{parallel}$ ：与阶段数相似度类似，基于最大并行度的绝对差值进行线性惩罚。

$$S_{parallel}(W_a, W_b) = \max(0, 1 - \beta_{parallel} \cdot |P_{max}(W_a) - P_{max}(W_b)|) \quad (6)$$

其中惩罚因子 $\beta_{parallel}$ 设为 0.2， $P_{max}(W)$ 为单个阶段内并行执行的最大节点数。

S_{seq} ：衡量两个多智能体系统在宏观执行流程上

的相似性。本文将定义为两个调用序列 $Seq(W_a)$ 和 $Seq(W_b)$ 之间的归一化编辑距离 (Normalized Levenshtein Distance)。

$$S_{seq}(W_a, W_b) = 1 - \frac{\text{Levenshtein}(Seq(W_a), Seq(W_b))}{\max(|Seq(W_a)|, |Seq(W_b)|)} \quad (7)$$

其中 $\text{Levenshtein}(\cdot)$ 计算将一个序列转换为另一个所需的最少单字符编辑 (插入、删除或替换) 次数。

最终，多智能体系统之间的相似度定义为：

$$S_{total}(W_a, W_b) = \frac{S_{types} + S_{stages} + S_{parallel} + S_{seq} + S_{struct}}{n} \quad (8)$$

其中， n 为相似度度量个数。

基于上述定义的多维度相似度度量，可以准确量化不同系统间的功能差异。以此为基础，第 3.2 节将利用社区发现算法对搜索空间进行结构化划分。

3.2 基于 Louvain 算法的多智能体系统家族发现

通过前续章节定义的多维度相似度度量，本文现在可以将离散的候选多智能体系统集合，转化为一个结构化的多智能体系统相似度图。这个图为本文从更高维度理解和划分搜索空间提供了可能。

3.2.1 多智能体系统相似度图的构建

本文将当前搜索池中的候选多智能体系统 $\{W_1, W_2, \dots, W_N\}$ 构建为一个加权无向图 $G = (V, E, w)$ ，其中：

1) 节点集 (Vertices) V ：每个节点 $v_i \in V$ 对应一个多智能体系统 W_i 。

2) 边集 (Edges)：理论上，这是一个全连接图，




图3 基于 Louvain 算法的多智能体系统家族发现

Fig.3 Family Discovery of Multi-Agent Systems Based on the Louvain Algorithm

每对节点 (v_i, v_j) 之间都存在一条边 e_{ij} 。

3) 权重函数(Weight) w : 每条边 e_{ij} 的权重被赋值
为本文计算出的两个多智能体系统之间的综合相似度
得分, 即 $w(e_{ij}) = S_{total}(W_i, W_j)$ 。

在实践中, 为凸显多智能体系统图的结构并降低
计算复杂度, 本文会设置一个相似度阈值 θ_{sim} (例如
0.65)。只有当 $S_{total}(W_i, W_j) \geq \theta_{sim}$ 时, 才在节点 v_i 和 v_j
之间保留这条边。这样, 本文就得到了一个稀疏的、
更能反映强关联关系的相似度图。

3.2.2 Louvain 算法与模块度优化

如图3所示, 获得了多智能体系统相似度图 G 后,
本文的目标是将其划分为若干个多智能体系统家族,
使得家族内连接(相似度)尽可能紧密, 而家族间的
连接尽可能稀疏。针对这一需求, 本文选择采用
Louvain 社区发现算法^[12], 其原因在于该方法与本研
究场景高度适配: 它作为一种高效的启发式算法, 能
直接作用于 3.2.1 中基于 MAS 专属多维指标所构建的
加权相似度图。相比之下, 其他先进的动态聚类方法
通常需要复杂的向量嵌入与
额外训练, 在本框架的迭代优化场景中效率和可解释
性均显不足。因此, 本文的创新点在于首次将 Louvain
社区发现算法与 MAS 专属相似度度量相结合, 使其
适配于 MAS 优化场景; 其次, 创新性地利用其聚类结
果指导 3.3 节的搜索策略, 以规避冗余探索。

Louvain 算法的核心正是最大化一个名为模块度
(Modularity) 的指标 Q 。模块度 Q 用于衡量一个图划分
方案的质量。其值域通常在 $[-0.5, 1]$ 之间, 越高的值代
表越显著的家族结构。其计算公式为:

$$Q = \frac{1}{2m} \sum_{i,j} \left[A_{ij} - \frac{k_i k_j}{2m} \right] \cdot \delta(c_i, c_j) \quad (9)$$

其中, A_{ij} 是图中所有边权重的总和。 A_{ij} 是节点 i 和 j
之间的边权重, 在本文的场景中即为 $S_{total}(W_i, W_j)$ 。

$k_i = \sum A_{ij}$ 是与节点 i 相连的所有边的权重之和(加权
度), c_i 是节点 i 被分配到的家族, $\delta(c_i, c_j)$ 是克罗内

克函数(Kronecker delta), 当节点 i, j 在同一家族时
($c_i = c_j$), 其值为 1, 否则为 0。

该公式的直观解释是: 它计算了多智能体系统家
族内部所有边的权重之和, 与保持所有节点度不变的
随机多智能体系统家族中, 家族内部边权重的期望值
之间的差值。一个好的家族划分, 其实际内部连接应
当是远超随机期望的。

3.2.3 算法流程

Louvain 算法通过一个迭代的两阶段过程来优化
模块度 Q :

阶段一: 局部模块度优化。初始时, 将图中的每个
节点(每个多智能体系统)都视为一个独立的家族。
遍历所有节点 i , 依次尝试将其从当前家族移动到其
每个邻居节点 j 所在的家族中。计算每次移动带来的
模块度增益 ΔQ 。将节点 i 移动到能使其获得最大正增
益 ΔQ 的邻居家族中。如果没有任何移动能带来正增
益, 则节点 i 保持原状。重复此过程, 直到图中所有节
点都无法通过移动来获得模块度增益, 即达到一个局
部的模块度最大值。

阶段二: 多智能体系统家族聚合与网络重构。将
阶段一中形成的每个多智能体系统家族视为一个新的
“宏节点”。构建一个新图, 其中宏节点之间的边权重
等于原始图中对应两个多智能体系统家族之间所有边
的权重之和。每个宏节点内部的边权重则转化为新图
中的自环权重。在新生成的“宏图”上, 重新执行阶段
一。这两个阶段不断重复, 直到网络的家族结构不再
变化, 模块度 $|F_i|$ 不再增大为止。算法最终输出的家
族划分结果, 即为本文识别出的多智能体系统家族。
这个划分结果将作为本文下一章中多样性感知搜索策
略与经验共享机制的基础。

3.3 多样性感知搜索策略与经验共享机制

在通过 Louvain 算法识别出多智能体系统家族后, 本
文便拥有了对搜索空间结构化的理解。这使本文能够
超越孤立地评估单个多智能体系统的局限, 从宏观视
角来指导后续的演化过程。为此, 本文设计了两种协




Fig.4 Diversity awareness search strategy and experience sharing mechanism

同工作机制：基于多智能体系统家族的代表选举策略用于保持搜索的多样性、避免冗余探索；跨多智能体系统的经验共享机制则用于加速优质解的迭代与优化。

3.3.1 基于多智能体系统家族的代表选举与多样性采样

在传统的演化算法中^[4]，通常会采用“精英主义”策略，即直接选择当前得分最高的若干个候选者作为下一轮优化的父代。然而，这种贪心策略的弊端在于，如果得分最高的几个多智能体系统恰好来自同一个家族（即它们的解决方案在功能上高度同质化），那么搜索过程就会过早地收敛到一个局部最优解，从而牺牲了全局探索的多样性。

为解决此问题，本文提出了“一族一代表”的选举与采样策略。如图 4 所示，其核心思想是从每个识别出的多智能体系统家族中，只选择一个代表进入下一轮的父代候选池。这样，无论一个家族内部包含了多少个高分成员，它在下一代中的“发言权”都只有一个，从而保证了不同设计思路（不同多智能体系统家族）的公平竞争和持续探索。

具体而言，选举过程采用概率性采样。对于一个包含 $|F_i|$ 个成员的多智能体系统家族 $F_i = \{W_1, W_2, \dots, W_{|F_i|}\}$ ，本文为其中的每个成员 W_j 计算一个选择概率 $P(W_j)$ 。该概率由两部分加权构成，分别是保证探索性的均匀概率和倾向于高分个体的 Softmax 概率：

$$P(W_j | F_i) = \lambda \cdot \frac{1}{|F_i|} + (1 - \lambda) \cdot \frac{\exp(\alpha \cdot s_j)}{\sum_{l=1}^{|F_i|} \exp(\alpha \cdot s_l)} \quad (10)$$

其中， s_j 是多智能体系统 w_j 的归一化性能得分。 α 是 Softmax 的温度系数，用于调节分数对概率分布的影响力。 λ 是平衡因子，用于调和均匀探索与分数驱动的利用之间的关系。

在计算出家族内所有多智能体系统的概率后，本文根据此概率分布进行随机抽样，选举出该家族的唯一

一代表多智能体系统 $W_{rep,i}$ 。通过对所有家族执行此操作，本文最终得到一个规模显著减小、但成员之间差异性得到保证的全新父代多智能体系统池。此策略有效地剪除了功能冗余的搜索路径，并将计算资源引导至更多样化的候选方案上。

最后，为确定本次演化迭代所使用的单个父本多智能体系统，本文需从这个由各家族代表组成的精英父代池 $\mathcal{R}$ 中再进行一次选择。为了在保持多样性的同时，还能兼顾多智能体系统的性能，本文在此最终选择阶段再次采用概率性采样。本文会根据池中各代表多智能体系统的性能得分 $s_{rep,i}$ ，通过 Softmax 函数为它们分配最终的选择概率：

$$P(W_{rep,i} | \mathcal{R}) = \frac{\exp(s_{rep,i})}{\sum_{j=1}^k \exp(s_{rep,j})} \quad (11)$$

通过这种方式最终选择出一个父本多智能体系统 W_{parent} 。这个被选中的多智能体系统，将携带其所属整个家族的集体智慧进入下一轮的优化与变异环节。

3.3.2 跨多智能体系统的家族经验共享

单个多智能体系统在其生命周期中积累的成功或失败经验是有限的。然而，同一家族内的成员由于其内在的功能相似性，它们在演化过程中遇到的挑战、尝试的修改策略以及最终的失败根因也往往具有共性。这些分布在不同多智能体系统中的碎片化经验，如果能够被汇集，将形成一笔宝贵的集体智慧。

为此，本文设计了家族经验共享机制。该机制的核心是在选举出家族代表后，将整个家族所有成员的“演化经验”进行池化，并注入给当选的代表。

具体来说，令 $\mathcal{E}(W)$ 为多智能体系统 W 的经验日志，其包含了所有成功的修改记录 $\mathcal{E}_{succ}(W)$ 和失败的修改记录 $\mathcal{E}_{fail}(W)$ 。对于一个多智能体系统家族 F_i ，其池化后的家族经验 $\mathcal{E}_{pooled}(F_i)$ 是该家族所有多智能体系统成功经验和失败经验的并集：

$$\mathcal{E}_{pooled, succ}(F_i) = \bigcup_{W_j \in F_i} \mathcal{E}_{succ}(W_j) \quad (12)$$

$$\mathcal{E}_{pooled, fail}(F_i) = \bigcup_{W_j \in F_i} \mathcal{E}_{fail}(W_j) \quad (13)$$

在选举出代表 $W_{rep,i}$ 后, 本文将这份更全面、更丰富的池化经验 $\mathcal{E}_{pooled}(F_i)$ 附加到该代表上。当上层的大语言模型(作为优化器)需要对 $W_{rep,i}$ 进行修改以创造新的子代时, 它所参考的将不再是 $W_{rep,i}$ 个体的单薄历史, 而是整个家族的集体经验总结。

这种机制极大地丰富了优化器进行决策时的上下文信息, 使其能够从更广泛的成功案例中归纳出有效的“设计模式”, 并从多样化的失败案例中吸取教训, 从而显著提升了对多智能体系统(尤其是对提示词)进行迭代优化的精准性和效率。

4 面向提示优化的细粒度反馈机制

前述章节提出的相似度感知搜索机制, 主要解决了在庞大的多智能体系统搜索空间中“探索什么”的问题, 它通过识别和剪除功能冗余的区域来提升搜索的宏观效率。然而, 要实现对一个有潜力的多智能体系统进行深度优化, 本文还必须解决“如何改进”的难题。

现有的大多数多智能体系统自动优化框架, 其核心驱动力源于一个稀疏且粗粒度的终端反馈信号, 即智能体系统在完成整个任务后得到的最终性能得分 $\mathcal{C}(W, T)$ 。这个单一的标量分数, 虽然能够评判一个智能体系统的整体优劣, 却无法揭示其内部的运作细节。这就导致了经典的信用分配难题: 当一个智能体系统失败或表现不佳时, 无法准确判断是哪一个智能体的决策失误、哪一段提示存在歧义, 或是哪一个节点的输出质量不佳, 从而拖累了整个系统的表现。

这种困境使得对具体组件的优化变得盲目且低效。优化过程不得不依赖于大量的随机变异和试错, 期望通过随机变异定位到问题的关键。特别是在优化大语言模型驱动的智能体时, 其提示词是一个语义丰富但结构脆弱的组件, 盲目的修改极易导致性能崩溃。因此, 要实现对智能体系统, 尤其是对各节点提示词的精准、高效优化, 就必须打破对单一终端反馈的依赖, 建立一套能够深入智能体系统内部、提供局部指导信号的细粒度反馈机制。

4.1 节点内置的细粒度反馈生成

为解决信用分配难题, 本文将全局、端到端的优化目标, 分解为一系列局部的、精确的节点级优化信号。本文提出一种节点内置的细粒度反馈机制。其核心思想并非引入一个独立的外部评估器, 而是通过增强节点的提示, 使每个下游节点在执行其核心任务之前, 先对接收到的上游节点输出进行自我评估。前置任务: 输入质量评估在提示的起始部分, 本文加入了一段明确的指令, 要求大语言模型首先扮演质量评估员的角色。它需要根据自身即将执行的核心任务, 来审视和评判从上游节点 a_i 接收到的输入 o_i 的质量。评

输入提示 (Prompt) :
You are a multi-task assistant. Your operation is a two-step process.

****Your Core Task:****
[Insert the core task description for node here]

****Provided Input:****
You have received the following data from the previous step:
<input_data>
{Input from the upstream node a_i}
</input_data>

****STEP 1: Input Quality Assessment****

Before executing your core task, first evaluate the quality of the '<input_data>'. Provide a numerical rating on a scale of 1-10 and a detailed justification inside the '<assessment>' tags.

****STEP 2: Core Task Execution****
After providing the assessment, proceed with your core task.

图5 基于XML标签的LLM提示词模板

Fig.5 LLM prompt word template based on XML tags
估的维度是综合性的可用性, 主要包括:

- 1) 完整性: 输入 o_i 是否包含了执行核心任务所需的所有信息?
- 2) 清晰度: 输入的格式是否规范、无歧义, 易于解析和利用?
- 3) 相关性: 输入中是否存在大量与核心任务无关的噪声信息?
- 4) 核心任务: 执行原始功能在完成前置的评估任务后, 提示的第二部分才要求模型继续执行其原本被赋予的核心功能。

为了确保这部分反馈能够被系统自动解析和利用, 本文要求模型将评估结果以结构化的格式(例如XML标签)嵌入其输出的起始位置。一个典型的增强后提示的模板如图5所示。

当节点 a_j 执行时, 它会生成一份包含两部分的输出: 一部分是被<assessment>标签包裹的、针对上游节点 a_i 的细粒度反馈 (s_{fine}, j_{fine}) 另一部分是它完成核心任务后得到的真正结果 o_j 。系统可以通过简单的格式解析, 同时获得用于优化的指导信号和用于智能体系统继续推进的数据。

形式化地, 对于上游节点 a_i 的输出 o_i , 其获得的细粒度反馈(s_{fine}, j_{fine})是下游节点 a_j 输出的一部分。这种将评估任务内置化的设计, 避免了引入额外节点的复杂性, 以一种极为高效的方式, 将原本隐性的、局部的执行经验显性化、结构化, 为后续的自动化优化闭环提供了关键依据。

表 1 主要实验结果
Table 1 Main experimental results

方法	Benchmarks						Avg. Score
	HotpotQA	DROP	HumanEval	MBPP	GSM8K	MATH	
IO	68.1	68.3	87.0	71.8	92.7	48.6	72.8
CoT	67.9	78.5	88.6	71.8	92.4	48.8	74.7
CoT SC(5-shot)	68.9	78.8	91.6	73.6	92.7	50.4	76.0
MedPrompt	68.3	78.0	91.6	73.6	90.0	50.0	75.3
MultiPersona	69.2	74.4	89.3	73.6	92.8	50.8	75.1
Self-Refine	60.8	70.2	87.8	69.8	89.6	46.1	70.7
ADAS	64.5	76.6	82.4	53.4	90.8	35.4	67.2
AFLOW	73.5	80.6	94.7	83.4	93.5	65.2	81.2
CAFG (本文方法)	75.8	83.9	96.5	86.1	96.1	67.3	84.2

5 性能评估

本章旨在通过一系列全面的实验，对本文提出的聚类感知与细粒度反馈驱动的多智能体系统自动优化方法的性能进行实证评估。本文将与一系列主流的人工设计方法，以及包括 ADAS 和 AFLOW 在内的自动化方法进行直接比较，以验证其在多个挑战性基准任务上的先进性。

5.1 实验设置

5.1.1 数据集

本文的实验采用了六个公认的基准数据集。遵循多智能体系统优化领域的既定惯例，本文将数据以 1:4 的比例划分为验证集和测试集。具体来说，本文使用了 GSM8K、HumanEval 和 MBPP 的全量数据集。对于 HotpotQA 和 DROP，本文遵循相关研究，各随机抽取 1000 个样本进行测试。对于 MATH 数据集，本文同样参考现有工作，选取了难度等级为 5 的四种典型问题类型（组合与概率、数论、初等代数、初等微积分）共 617 个问题。

5.1.2 对比基线

本文将 CAFG 发现的多智能体系统与以下三类方法进行比较：

基础调用方法：直接调用 LLM (directly invocation, IO) 和思维链 (Chain-of-Thought, CoT) [26]。

复杂人工设计方法：包括 Self Consistency CoT (SC-CoT) [27]、MedPrompt [28]、MultiPersona Debate [29] 以及 Self-Refine [30]，这些方法代表了当前通过精巧提示工程所能达到的较高水平。

自动化优化方法：本文选择了两种代表性的智能体系统自动优化方法作为核心竞争对手，即 ADAS [13] 和当前领域的先进方法 AFLOW [7]。

5.1.3 实现细节

本文的方法 CAFG 采用 DeepSeek-R1 [31] 作为核心的优化器，负责根据相似度聚类 and 细粒度反馈生成和迭代多智能体系统。为保证公平性，实验中所有方法（包括所有基线和本文的 CAFG）的多智能体系统节点均统一使用 DeepSeek-V3 [32] 作为执行器。所有模型均通过 API 访问，执行器模型的温度 (temperature) 设为 0 以保证结果的可复现性。实验中所有需要迭代优化的方法的总迭代轮数均设置为 12 轮。

5.1.4 评测指标

对于 GSM8K 和 MATH 数据集，本文采用解决率 (Solve Rate, %) 作为主要指标。对于 HumanEval 和 MBPP 这两个代码生成任务，本文报告 pass@1 [33][33] 指标。对于 HotpotQA 和 DROP 问答任务，本文报告 F1 分数 (F1 Score)。此外，表 1 中的 Avg. Score 由以下公式计算得出：

$$\text{Avg. Score} = \frac{1}{6} \sum_{d \in D} \text{Score}_d \quad (14)$$

其中， $D = \{\text{HotPotQA}, \text{DROP}, \text{HumanEval}, \text{MBPP}, \text{GSM8K}, \text{MATH}\}$ ， Score_d 是方法在对应数据集 d 上的得分。

5.2 综合性能对比分析

表 1 的实验数据全面地展示了本文提出方法的优越性。本文的方法在全部六个基准测试中均取得了当前最佳性能 (State-of-the-Art)，平均分达到了 84.2，这证明了其强大的有效性和广泛的适用性。

与依赖人类专家知识的人工设计方法相比，CAFG 的优势是全方位的。即便是其中表现最好的 SC-CoT (平均分 76.0%)，CAFG 依然领先了 8.2 个百分点。这表明，对于复杂的多智能体协作模式，自动化搜索发现的策略能够超越人类直觉和现有经验。其次，在与自动化优化方法的对决中，CAFG 的先进性

得到了充分验证。相较于早期的 ADAS 方法, CAFG 实现了平均 17 个百分点的显著性能提升。更重要的是, 与当前同样表现出色的 AFLOW 方法相比, CAFG 在其已达到的高基准上, 实现了稳定的再提升(平均分 84.2 vs 81.2)。特别是在对逻辑推理和代码生成能力要求极高的 HumanEval、MBPP 和 MATH 数据集上, CAFG 均取得了最佳性能表现, 例如在极具挑战性的 MATH 数据集上, CAFG 将解决率提升至 67.3%。本文认为, CAFG 的性能优势不仅体现在表 1 所示的最终得分上, 更关键地体现在其优化过程的效率与精度上。为了从动态过程的视角深入分析 CAFG 方法的优化效率, 并阐明两大核心模块的协同增益本质, 本文在 MATH 数据集上追踪并绘制了包含核心消融模块 (CAFG(a)与 CAFG(b)) 的完整性能收敛曲线, 如图 6 所示, 该图直观地展示了 CA 与 FG 两个模块各自的独特贡献以及它们之间深刻的互补关系:

CA 模块决定探索效率: 首先, CAFG(a)曲线(绿色方块)验证了聚类感知(CA)模块的贡献。该曲线在优化的初始阶段(第 1-6 轮)便迅速攀升, 其斜率远超基线(蓝色圆点), 几乎与 CAFG 完整方法(红色圆点)的早期斜率一致。这有力地表明, CA 模块通过规避冗余探索, 显著提升了全局探索的效率。然而, 该曲线在后期趋于平缓, 其性能上限(约 66.1 分)低于 CAFG 完整方法, 这表明仅有高效的全局探索, 仍缺乏对当前多智能体系统进行深度打磨的能力。

FG 模块决定优化精度: 其次, CAFG(b)曲线(紫色三角)展示了细粒度反馈(FG)模块的价值。该曲线的初始收敛速度与基线同样缓慢, 这说明在缺乏高效全局探索策略时, FG 模块难以快速定位到优质解区域。但在优化的后期阶段(第 8-12 轮), FG 模块的深度挖掘能力使其得以突破基线 AFLOW 的性能平台, 达到了更高的性能上限(约 65.7 分)。

协同增益: 最终, CAFG 完整方法(红色圆点)的曲线揭示了协同增益的本质。CAFG 并非两大模块的简单叠加, 而是一种高效的互补融合。CA 模块在宏观层面负责广度探索, 为算法提供多样化的高潜力候选多智能体系统; 而 FG 模块在微观层面负责深度优化, 对 CA 模块筛选出的高潜力候选者进行精准的打磨。正是这种 CA 模块为 FG 模块持续提供高质量优化目标的机制, 使得 CAFG 方法能够同时继承 CA 模块的收敛速度和 FG 模块的性能上限, 最终取得了超越任一独立模块所能达到的性能水平(67.3%)。

综上所述, 收敛曲线清晰表明 CAFG 不仅能够找到更优的解决方案, 还能以更快的速度、更稳定的路径达成目标, 实现了优化效率与最终效果的双重提升。

5.3 消融实验

为了深入剖析 CAFG 框架的有效性, 我们设计了两组消融实验。第一组实验旨在验证两大核心创新——聚类感知搜索(Cluster-Aware Search, CA)与细粒度反馈(Fine-Grained Feedback, FG)的独立贡献与协同效应。第二组实验则进一步深入 CA 模块内部, 对其多维度




图 6 MATH 数据集迭代过程中的性能收敛曲线

Fig.6 The performance convergence curve during the iterative process of the MATH dataset

相似度量方法中的各个组件进行独立的有效性验证。所有实验均以强基线方法 AFLOW 为起点, 以量化我们提出的各个模块和组件在现有先进技术基础上的增量价值。

5.3.1 核心模块贡献分析

本文首先评估 CA 与 FG 两大核心模块的整体作用, 实验设置如下:

1) 基线方法 (AFLOW): 一个极具竞争力的自动化搜索方法, 作为衡量本文模块成效的起点基线。在此设置中, CA 与 FG 模块均未激活。

2) CAFG(a): 在基线方法的基础上, 仅集成聚类感知 (CA) 模块, 旨在独立验证该模块在优化搜索空间、提升探索效率方面的价值。

3) CAFG(b): 在基线方法的基础上, 仅集成细粒度反馈 (FG) 模块, 用以单独评估该模块在精准信用分配与深度优化多智能体系统方面的能力。

4) CAFG: 本文的完整方法, 集成了聚类感知 (CA) 与细粒度反馈 (FG) 两大模块, 展示了它们协同工作时的最终性能。

表 2 的结果清晰地展示了一条从现有先进基线通往更高性能的演进路径。首先, 基线方法 AFLOW 本身在各项任务中已展现出强大的性能, 这为衡量我们所提模块的增量价值构成了一个极具挑战性的起点。在此基础上, 我们可以清晰地量化两大核心模块的独立贡献:

1) 聚类感知的价值: 通过对比基线方法与 CAFG(a) (仅集成 CA 模块) 的结果, 可以发现模型性能在所有任务上都获得了稳定的提升。例如, 在 MATH 和 HumanEval 任务上, 性能分别提升了 0.9% 和 0.4%。为了进一步量化 CA 模块在规避冗余探索方面的有效性,

表 2 核心模块消融实验结果
Table 2 The results of the core module ablation experiment

方法	消融模块		HotpotQA	DROP	HumanEval	MBPP	GSM8K	MATH	MAS 平均 相似度
	CA	FG							
AFLOW	×	×	73.5	80.6	94.7	83.4	93.5	65.2	63%
CAFG(a)	√	×	74.8	82.9	95.1	84.2	94.7	66.1	55%
CAFG(b)	×	√	73.8	81.9	95.2	84.1	94.6	65.9	62%
CAFG	√	√	75.8	83.9	96.5	86.1	96.1	67.3	54%

表 3 相似度量消融实验结果
Table 3 The results of the similarity measurement ablation experiment

方法	S_{stages}	$S_{parallel}$	S_{types}	S_{seq}	S_{struct}	MATH
基线方法	×	×	×	×	×	65.2
CAFG(c)	√	×	×	×	×	65.5
CAFG(d)	×	√	×	×	×	65.6
CAFG(e)	×	×	√	×	×	66.1
CAFG(f)	×	×	×	√	×	66.5
CAFG(g)	×	×	×	×	√	66.7
CAFG	√	√	√	√	√	67.3

表 2 最后一列引入了“MAS 平均相似度”指标。该指标计算了最终 MAS 种群的相似度矩阵(如图 8)的均值,该值越低,代表种群多样性越高、冗余探索越少。从表中可见,AFLOW 基线的平均相似度高达 63%,而 CAFG(a)的平均相似度显著下降至 55%。这一数据提供了强有力的量化证据,证明了我们的相似度感知聚类机制是有效的。它通过识别并剪除功能同质化的多智能体系统家族,成功缓解了传统搜索中的冗余探索问题,从而将宝贵的计算资源引导至更有潜力的新颖结构上。作为对比,CAFG(b)(未集成 CA 模块)的平均相似度为 62%,与基线 AFLOW 基本一致,这进一步证实了种群多样性的提升(即平均相似度的降低)完全归功于 CA 模块。

2) 细粒度反馈的价值: 同样地, CAFG(b)(仅集成 FG 模块)相较于基线方法也在所有基准测试中取得了显著的性能增益。例如,在 DROP 和 MBPP 任务上,性能分别提升了 1.3%和 0.7%。这说明,即便宏观搜索策略不变,仅仅通过引入节点级的反馈,也能显著提升多智能体系统的最终表现。FG 机制有效解决了信用分配难题,为多智能体系统的深度优化提供了传统终端反馈无法企及的精确指导。

最后,当两大模块在 CAFG 框架中协同工作时,模型的性能达到了顶峰,全面超越了所有对比项。更重要的是,其整体性能增益(例如在 HotpotQA 上提升 2.3%,在 DROP 上提升 3.3%)显著高于两个模块独立贡献的简单叠加,这揭示了两者之间存在着强大的正向协同效应。该效应源于两个模块在优化流程中所扮

演的互补角色: 聚类感知(CA)模块负责在宏观层面提升全局探索的效率,它通过管理和维护一个结构多样化的候选者种群,确保算法不会过早地收敛到一个解法范式中;而细粒度反馈(FG)模块则在微观层面增强了局部优化的精度,它通过提供精确的节点级指导信号,对由 CA 模块筛选出的、具有高潜力的候选者进行高效的深度挖掘和完善。二者的结合,构建了一个兼顾广度探索与深度优化的、更为稳健的整体优化流程,从而取得了超越任一独立模块的卓越性能表现。

5.3.2 相似度量组件分析

在验证了 CAFG 两个模块的有效性后,本文进一步对其内部的多维度相似度量方法进行了更细致的消融研究,以探究每个相似度组件的独立贡献。我们以考验逻辑推理能力的 MATH 数据集为例,分别评估了仅使用单一相似度指标(S_{stages} 、 $S_{parallel}$ 、 S_{types} 、 S_{seq} 、 S_{struct})时的性能。实验结果如表 3 所示。

基础影响力组件: S_{stages} 和 $S_{parallel}$ 这两个宏观拓扑指标也带来了正向收益,性能分别达到 65.5 分(+0.3)和 65.6 分(+0.4)。虽然它们提供的信息粒度最粗,但依然为识别和排除结构差异过大的候选方案提供了有效的基础启发。

高影响力组件: 仅使用代码层面的或流程层面的 S_{struct} 和 S_{seq} 时,模型性能获得了最大的单项提升,分别达到了 66.7 分(+1.5)和 66.5 分(+1.3)。这表明多智能体系统的代码实现和宏观调用序列是定义其核心功能的关键,有效度量这两点能够高效地规避冗余探索。

中等影响力组件: 仅使用 S_{types} 时,性能获得了 66.1 分(+0.9)的中度提升。这说明,即使不考虑流程顺序,仅仅分析多智能体系统的节点构成,也能为搜索提供有效的引导。

组合协同价值: 值得注意的是,尽管最强的单一指标 S_{struct} 已带来显著提升,但融合全部五个指标的完整 CAFG 模型达到了 67.3 分的最佳成绩,获得了 2.1 个百分点的最大增益。这证明了本文提出的多维度度量方法的鲁棒性与协同价值: 通过整合来自不同层面




图 7 MATH 数据集中的多智能体系统优化路径示意图

Fig.7 Schematic diagram of the optimization path for multi-agent systems in the MATH dataset

的信息，模型能够得到比任何单一维度更全面、更准确的相似性判断，从而实现最优的搜索效率。

5.4 可视化分析

为了更直观地展示本文提出的聚类感知与细粒度反馈 (CAFG) 方法在优化过程中的优势，本文对搜索过程的演化路径和最终候选多智能体系统的相似度进行了可视化，并与基线方法进行了对比，结果如图 7 和 8 所示。

5.4.1 演化路径动态对比

图 7 的演化树直观地揭示了不同算法在搜索动态和策略倾向上的本质差异，尤其是它们在处理探索多样性与冗余性上的不同方式。

首先观察基线方法的演化路径（图 7(b)），其呈现出一种“集中爆发式”但冗余的探索模式。在其初始探索阶段，根节点 1 衍生出的三个主要子节点（8, 3, 2）全部隶属于同一个多智能体系统家族（红色家族 2）。这表明，当算法试图从初始状态向新方向探索时，它倾向于一次性生成多个功能高度相似的候选者。这种策略虽然看似扩大了搜索宽度，但实质上造成了计算资源的浪费，构成了冗余探索，因为这些相似的后代很可能是在同一狭窄的解决方案区域内进行微小变动。

相比之下，CAFG 方法的演化路径（图 7(a)）则展现出一种更高效、更多样化的探索策略。其根节点 1 在衍生后代时，同时探索了两个方向：一个是全新思路的绿色后代 2（家族 2），代表了对新领域的“广度探索”；另一个是与自身同源的红色后代 5，代表了对现有思路的“深度挖掘”。在此基础上，后续的演化进一步引入了家族 5 和家族 6 等更多完全不同的家族。值得注意的是，CAFG 还演化出了一条深度探索长链（节点 1→2→3→4→7），这条长链进一步证明了 CAFG 能够识别并持续优化有潜力的方向。

这一对比清晰地表明：CAFG 的聚类感知机制能够有效识别并规避功能同质化的探索方向，避免了基线方法在单一新思路上的过度聚集现象。它通过在维持既有优势方向与开拓全新解决方案范式之间取得动

态平衡，实现了对多智能体系统空间更广泛且资源效率更高的覆盖，从而显著减少了冗余探索，并将算力集中于发现更多样、更有潜力的解决方案。

5.4.2 相似度结构结果对比

演化过程的差异最终体现在生成多智能体系统的相似度上，相似度矩阵的可视化结果（图 8）为这一论点提供了直接证据。

首先，从图 8(b)可以看出，基线方法 AFLOW 后续生成的多智能体系统（如 2 至 12）与初始多智能体系统 1 的相似度整体呈现出变化的趋势，这表明搜索过程确实在逐步远离其出发点，进行着有效的探索，避免了陷入局部最优或返回初始状态的问题。然而，这种探索的效率并不高。矩阵热力图呈现出大范围的中高相似度值（橙色区域），缺乏清晰的聚类结构。这说明，尽管算法在不断探索，但其新产生的候选者之间功能高度相关，最终收敛于同一个宽泛解决方案区域内的不同变体。因此，可以认为基线方法的探索存在一定的冗余性。

相比之下，CAFG 方法（图 8(a)）不仅保留了这种远离初始解的有效探索特性，并且极大地提升了探索的效率和质量。其结果呈现出高度结构化的特征：热力图上形成了多个边界分明、内部相似度极高的聚类区块（深红色区域），例如由多智能体系统 {10, 12} 构成的群组。同时，这些区块被低相似度的区域（白色及蓝色）明确分离。这种“高内聚、低耦合”的分布形态证明，CAFG 的探索并非随机无序的，而是有导向性地发现并收敛于多个、功能各异的优质解空间。

综上所述，CAFG 的优势在于，它继承了有效探索的本质，并通过其聚类感知机制，成功抑制了冗余探索，将搜索资源引导至发现结构更多样、性能更优越的多智能体系统上，从而实现了探索广度与收敛效率的更优平衡。

6 结论与展望

本文针对现有大语言模型多智能体系统自动化优




图8 MATH 数据集中的多智能体系统相似度可视化

Fig.8 Visualization of similarity of multi-agent systems in the MATH dataset

化方法中,普遍存在的搜索冗余与信用分配模糊两大核心瓶颈,进行了一次系统的探索与实践。为解决这些挑战,本文设计并实现了一个新颖的、名为 CAFG 的自动化优化方法。该方法通过引入基于相似度图谱的聚类感知搜索和节点内置的细粒度反馈两大核心机制,显著提升了在复杂多智能体系统设计空间中进行自动化探索的效率与精度。实验结果表明,本文所提出的多维度相似度度量方法与社区发现算法相结合,成功构建了一套有效的聚类感知搜索策略,证实了其在规避功能同质化区域上的作用;同时,所设计的节点级细粒度反馈机制,通过将全局优化目标分解为局部的可解释信号,被证明是实现内部组件(尤其是提示词)精准、高效优化的关键。

尽管本研究取得了令人鼓舞的成果,但本文同样认识到其在效率和广度上仍存在提升空间。在效率方面,多智能体系统相似度矩阵的计算也面临着二次方复杂度的可扩展性挑战;未来的工作可以探索近似聚类等技术以应对这一问题。在广度方面,本框架的性能表现高度依赖于强大的大语言模型,且目前仅以性能为单一优化目标。因此,将框架适配于更多样化的模型,并拓展为一个能够协同优化成本、延迟和可解释性等多维指标的多目标优化系统,将是其迈向更广泛实际应用的关键所在。此外,本文对于多智能体系统相似度的衡量也存在一定的不足,未来的工作可以探索使用图神经网络的方法实现多智能体系统相似度的计算。

本文相信,通过更高效的搜索策略和更精准的优化信号来赋能多智能体系统的自动化设计,是推动复杂 AI 系统能力边界的关键。希望本文的工作能为相关领域的研究者提供有益的参考与启示。

参考文献:

- [1] LI X, WANG S, ZENG S, et al. A survey on LLM-based multi-agent systems: workflow, infrastructure, and challenges[J]. Vicinagearth, 2024, 1(1): 9.
- [2] TALEBIRAD Y, NADIRI A. Multi-agent collaboration: harnessing the power of intelligent llm agents[J]. arXiv preprint arXiv:2306.03314, 2023.
- [3] HONG S, ZHUGE M, CHEN J, et al. Metagpt: meta programming for a multi-agent collaborative framework[C]//Proceedings of the Twelfth International Conference on Learning Representations (ICLR 2024). Vienna, Austria, 2024.
- [4] ZHUGE M, WANG W, KIRSCH L, et al. Gptswarm: language agents as optimizable graphs[C]//Proceedings of the Forty-first International Conference on Machine Learning (ICML 2024). Vienna, Austria, 2024.
- [5] CHEN W, SU Y, ZUO J, et al. Agentverse: facilitating multi-agent collaboration and exploring emergent behaviors in agents[J]. arXiv preprint arXiv:2308.10848, 2023, 2(4): 6.
- [6] 许旻辰,屈丹,司念文,等. 多维度多智能体分组讨论的虚假新闻检测方法[J]. 计算机工程与应用, 2025, 61(22): 183-195.
- [7] XU M C, QU D, SI N W, et al. Multi-dimensional and multi-agent group discussion method for fake news detection[J]. Journal of Computer Engineering and Applications, 2025, 61(22): 183-195.
- [8] ZHANG J Y, XIANG J Y, YU Z Y, et al. Aflow: automating agentic workflow generation[C]//Proceedings of the Thirteenth International Conference on Learning Representations (ICLR 2025). Singapore, Singapore, 2025.
- [9] JAMES F. Monte Carlo theory and practice[J]. Reports on progress in Physics, 1980, 43(9): 1145.
- [10] ZHOU H, WAN X, SUN R, et al. Multi-Agent design: optimizing agents with better prompts and topologies[J]. arXiv preprint arXiv:2502.02533, 2025.
- [11] WANG Y, YANG L, LI G, et al. Scoreflow: mastering llm agent workflows via score-based preference optimization[J]. arXiv preprint arXiv:2502.04306, 2025.
- [12] RAFAILOV R, SHARMA A, MITCHELL E, et al. Direct preference optimization: your language model is secretly a

- reward model[C]//Proceedings of the Advances in Neural Information Processing Systems 36 (NeurIPS 2023). New Orleans, USA, 2023: 53728-53741.
- [12] BLONDEL V D, GUILLAUME J L, LAMBIOTTE R, et al. Fast unfolding of communities in large networks[J]. Journal of statistical mechanics: theory and experiment, 2008, 2008(10): P10008.
- [13] HU S, LU C, CLUNE J. Automated design of agentic systems[C]//Proceedings of the Thirteenth International Conference on Learning Representations (ICLR 2025). Singapore, Singapore, 2025.
- [14] [1]李鹏,陈少飞,易楚舒,等.多智能体风险决策理论与方法研究综述[J].计算机学报,2025,48(10):2338-2370.
LI P, CHEN S F, YI C S, et al. Theories and methods of multi-agent decision under risk: a survey[J]. Chinese Journal of Computers, 2025, 48(10): 2338-2370.
- [15] 王龙,黄锋.多智能体博弈、学习与控制[J].自动化学报, 2023, 49(03): 580-613.
WANG L, HUANG F. An interdisciplinary survey of multi-agent games, learning, and control[J]. Acta Automatica Sinica, 2023, 49(03): 580-613.
- [16] CHEN G Y, DONG S W, SHU Y, et al. Autoagents: a framework for automatic agent generation[C]//Proceedings of the Thirty-Third International Joint Conference on Artificial Intelligence (IJCAI 2024). Jeju, South Korea, 2024: 22-30.
- [17] SONG L, LIU J, ZHANG J, et al. Adaptive in-conversation team building for language model agents[J]. arXiv preprint arXiv:2405.19425, 2024.
- [18] ZHENG C, CHEN J, LYU Y, et al. MermaidFlow: redefining agentic workflow generation via safety-constrained evolutionary programming[J]. arXiv preprint arXiv:2505.22967, 2025.
- [19] 袁晓铭,田汉森,黄锬达,等.数字孪生架构下基于GAN增强的多智能体深度强化学习边缘推理与异构资源协同优化[J].计算机学报, 2025, 48(08): 1763-1780.
YUAN X M, TIAN H S, HUANG K D, et al. A GAN-enhanced multi-agent deep reinforcement learning for digital twin-driven edge inference and heterogeneous resource co-optimization[J]. Chinese Journal of Computer s, 2025, 48(08): 1763-1780.
- [20] ZHANG G, YUE Y, SUN X, et al. G-designer: architecting multi-agent communication topologies via graph neural networks[J]. arXiv preprint arXiv:2410.11782, 2024.
- [21] KIPF T N, WELING M. Variational graph auto-encoders[J]. arXiv preprint arXiv:1611.07308, 2016.
- [22] LIU Z, ZHANG Y, LI P, et al. Dynamic llm-agent network: an llm-agent collaboration framework with agent team optimization[J]. arXiv preprint arXiv:2310.02170, 2023.
- [23] 李艺春,刘泽娇,洪艺天,等.基于多智能体强化学习的博弈综述[J].自动化学报, 2025, 51(03): 540-558.
LI Y C, LIU Z J, HONG Y T, et al. Multi-agent reinforcement learning based game: a survey[J]. Acta Automatica Sinica, 2025, 51(03): 540-558.
- [24] FINN C, ABBEEL P, LEVINE S. Model-agnostic meta-learning for fast adaptation of deep networks[C]//Proceedings of the 34th International Conference on Machine Learning (ICML 2017). Sydney, Australia, 2017: 1126--1135.
- [25] ZHU R, JIANG B, MEI L, et al. AdaptFlow: adaptive workflow optimization via meta-learning[J]. arXiv preprint arXiv:2508.08053, 2025.
- [26] WEI J, WANG X Z, SCHUURMANS D, et al. Chain-of-thought prompting elicits reasoning in large language models[C]//Proceedings of the Advances in Neural Information Processing Systems 35 (NeurIPS 2022). New Orleans, USA, 2022: 24824-24837.
- [27] WANG X Z, WEI J, SCHUURMANS D, et al. Self-consistency improves chain of thought reasoning in language models[C]//Proceedings of the The Eleventh International Conference on Learning Representations (ICLR 2023). Kigali, Rwanda, 2023.
- [28] NORI H, LEE Y T, ZHANG S, et al. Can generalist foundation models outcompete special-purpose tuning? case study in medicine[J]. arXiv preprint arXiv:2311.16452, 2023.
- [29] WANG Z H, MAO S G, WU W S, et al. Unleashing the emergent cognitive synergy in large language models: a task-solving agent through multi-persona self-collaboration[C]//Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (Volume 1: Long Papers) (NAACL 2024). Mexico City, Mexico, 2024: 257-279.
- [30] MADAAN A, TANDON N, GUPTA P, et al. Self-refine: iterative refinement with self-feedback[C]//Proceedings of the Advances in Neural Information Processing Systems 36: Annual Conference on Neural Information Processing Systems 2023 (NeurIPS 2023). New Orleans, LA, USA, 2023: 46534-46594.
- [31] GUO D, YANG D, ZHANG H, et al. Deepseek-r1: incentivizing reasoning capability in llms via reinforcement learning[J]. arXiv preprint arXiv:2501.12948, 2025.
- [32] LIU A, FENG B, XUE B, et al. Deepseek-v3 technical report[J]. arXiv preprint arXiv:2412.19437, 2024.
- [33] COBBE K, KOSARAJU V, BAVARIAN M, et al. Training verifiers to solve math word problems[J]. arXiv preprint arXiv:2110.14168, 2021.